

Теоретический конспект №2

Тема: Фреймворк обучения с подкреплением (Reinforcement Learning Framework)

Связано с: [note 1.md](#) — Введение в Deep Reinforcement Learning

1. Общая идея цикла «агент–среда»

Обучение с подкреплением (RL) — это **итеративный процесс взаимодействия** между двумя компонентами:

- **Агент (Agent)** — принимает решения, выбирает действия.
- **Среда (Environment)** — реагирует на эти действия, изменяя своё состояние и возвращая вознаграждение.

Цикл взаимодействия (Agent–Environment Loop)

На каждом временном шаге t :

1. Агент наблюдает текущее **состояние** среды

$$s_t \in \mathcal{S}$$

где $\mathcal{S}$ — множество всех возможных состояний.

2. На основе стратегии (policy) агент выбирает **действие**

$$a_t \in \mathcal{A}(s_t)$$

где $\mathcal{A}(s_t)$ — множество допустимых действий в состоянии s_t .

3. Среда выполняет это действие и возвращает:

- **Новое состояние** s_{t+1}
- **Награду** (reward)

$$r_{t+1} = r(s_t, a_t)$$

4. Агент обновляет своё знание/стратегию и переходит к следующему шагу.

Таким образом, процесс взаимодействия можно записать как **последовательность**:

$$(s_0, a_0, r_1, s_1, a_1, r_2, \dots)$$

2. Формализация через MDP

Чтобы описывать RL-агентов математически, используется модель **Марковского процесса принятия решений (Markov Decision Process, MDP)**:

$$\mathcal{M} = (\mathcal{S}, \mathcal{A}, P, r, \gamma)$$

где:

Символ	Компонент	Описание
$\mathcal{S}$	State space	Множество состояний среды
$\mathcal{A}$	Action space	Множество действий агента
$P(s' \mid s, a)$	Transition probability	Вероятность перехода из s в s' при действии a
$r(s, a)$	Reward function	Среднее вознаграждение при выполнении a в состоянии s
$\gamma \in [0, 1)$	Discount factor	Коэффициент дисконтирования будущих наград

3. Цель агента

Агент стремится **максимизировать ожидаемое суммарное вознаграждение** (expected return):

$$G_t = \sum_{k=0}^{\infty} \gamma^k r_{t+k+1}$$

Интуиция:

- r_{t+k+1} — награда через k шагов;

- γ^k — уменьшает вклад награды с течением времени;
- чем ближе награда, тем выше её «вес» в принятии решения.

4. Гипотеза вознаграждения (Reward Hypothesis)

Центральный принцип Reinforcement Learning:

Любая цель может быть представлена как **максимизация ожидаемого накопленного вознаграждения**.

Формализация

Если агент взаимодействует со средой во времени, то в момент времени t он получает последовательность наград:

$$r_{t+1}, r_{t+2}, r_{t+3}, \dots$$

Тогда его **суммарное (накопленное) вознаграждение** (return, G_t) определяется как:

$$G_t = r_{t+1} + \gamma r_{t+2} + \gamma^2 r_{t+3} + \dots = \sum_{k=0}^{\infty} \gamma^k r_{t+k+1}$$

где $\gamma \in [0, 1)$ — коэффициент дисконтирования, уменьшающий важность будущих вознаграждений.

Ключевое наблюдение

Эта гипотеза утверждает, что **все формы целенаправленного поведения** — будь то:

- обучение ходить, играть или торговать,
- управление ракетой или автомобилем,
- оптимизация стратегии инвестиций,

— могут быть сведены к **максимизации ожидаемого суммарного вознаграждения**.

Даже если внешне цель агента — нечто сложное (например, “приземлиться на Луну”), в терминах RL она формулируется как “получить наибольшее суммарное вознаграждение от действий, ведущих к успешной посадке”.

Почему это важно

1. **Единая математическая основа.** Любую задачу можно выразить через награды и их ожидание, что делает RL универсальной теорией обучения через опыт.

2. **Отсутствие прямых меток (label-free learning)**. В отличие от supervised learning, агент не знает «правильного ответа» — он **сам формирует стратегию** через пробу, ошибку и награды.

3. **Гибкость целевой функции**. Изменив определение вознаграждения, можно полностью изменить поведение агента:

- вознаграждение за скорость → быстрая игра;
- вознаграждение за точность → осторожное поведение.

4. **Эмерджентное поведение**. Сложные навыки часто возникают *автоматически*, как побочный результат максимизации общей награды (пример — агенты, которые научились прыгать, избегая врагов, хотя им это явно не предписывалось).

Математическая формулировка цели

Агент стремится найти оптимальную политику π^* , максимизирующую ожидаемую сумму дисконтированных вознаграждений:

$$\pi^* = \arg \max_{\pi} \mathbb{E}_{\pi}[G_t]$$

где $\pi(a|s)$ — политика (вероятность выбрать действие a в состоянии s).

Агент учится выполнять последовательность действий, которая **максимизирует ожидаемое значение G_t** .

5. Марковское свойство

Определение: Процесс удовлетворяет **свойству Маркова**, если:

$$P(s_{t+1} \mid s_t, a_t, s_{t-1}, a_{t-1}, \dots, s_0, a_0) = P(s_{t+1} \mid s_t, a_t)$$

То есть:

Будущее зависит **только от текущего состояния и действия**, а не от всей истории.

Это свойство делает MDP (Markov Decision Process) **управляемым** — мы можем рассматривать обучение агента, опираясь лишь на текущее наблюдение.

6. Простая иллюстрация (пример с игрой)

Допустим, агент обучается играть в простую платформенную игру:

1. **Состояние** s_t — кадр с изображением уровня.
2. **Действие** a_t — движение вправо, прыжок и т. д.
3. **Награда** r_t — +1 за сбор монеты, -10 за смерть.
4. **Новое состояние** s_{t+1} — следующий кадр.

Агент проходит через этот цикл тысячи раз, пока не выработает стратегию, **максимизирующую общую награду**.

7. Политика агента (Policy)

Политика — это способ, по которому агент выбирает действия:

- **Стохастическая политика:**

$$\pi(a|s) = P(A_t = a \mid S_t = s)$$

- **Детерминированная политика:**

$$a_t = \pi(s_t)$$

Цель обучения — найти **оптимальную политику** π^* , при которой:

$$\pi^* = \arg \max_{\pi} \mathbb{E}_{\pi}[G_t]$$

8. Различие между состоянием и наблюдением

Иногда агент не видит всё состояние мира (частично наблюдаемая среда):

Тип среды	Что видит агент	Пример
Полностью наблюдаемая	Всё состояние s_t	Шахматы (вся доска видна)
Частично наблюдаемая	Лишь наблюдение o_t	Super Mario (виден фрагмент уровня)

9. Пространства действий

- **Дискретное пространство:** конечное число действий (влево, вправо, прыгнуть).

- **Непрерывное пространство:** действие может принимать любое значение (например, угол поворота руля в автопилоте).

10. Дисконтирование наград

Чтобы не переоценивать далёкие вознаграждения, используется **дисконтирование**:

$$G_t = r_{t+1} + \gamma r_{t+2} + \gamma^2 r_{t+3} + \dots$$

Если $\gamma = 0.9$, то через 3 шага вес награды составит $0.9^3 = 0.729$.

→ Таким образом, агент **балансирует** между краткосрочными и долгосрочными выгодами.

Краткий итог

Компонент	Обозначение	Описание
Состояние	s_t	описание среды
Действие	a_t	выбор агента
Награда	r_t	обратная связь
Переход	$P(s' s, a)$	динамика среды
Политика	$\pi(a s)$	стратегия агента
Цель	$\max_{\pi} \mathbb{E}[G_t]$	максимизация ожидаемого вознаграждения

Основано на:

- Sutton & Barto, *Reinforcement Learning: An Introduction* (2020)
- Andrea Lonza, *Алгоритмы обучения с подкреплением на Python* (2020)
- RL Theory Book (Forts & Mills, 2022)