

Теоретический конспект №3

Тема: Компромисс «исследование / использование» (Exploration vs. Exploitation)

Связано с: [note 1.md](#) · [note 2.md](#)

1. Проблема выбора: «Известное» или «новое»?

В обучении с подкреплением агент постоянно сталкивается с дилеммой:

Что лучше сделать сейчас — использовать известное выгодное действие или попробовать новое, чтобы узнать больше о среде?

Эта дилемма лежит в основе любого RL-алгоритма.

Exploration (исследование)

Исследование означает, что агент **пробует новые действия**, чтобы **собрать больше информации о среде**. Это позволяет узнать, **где находятся потенциально более выгодные награды**, даже если текущее действие кажется неэффективным.

Пример:

Мышь в лабиринте решает свернуть в неизвестный коридор, чтобы проверить, нет ли там более крупного куска сыра.



Пример лабиринта

Формально, исследование помогает **оценить неизвестные переходы** $P(s'|s, a)$ и награды $r(s, a)$.

Exploitation (использование)

Использование — это применение **уже накопленных знаний**, чтобы **максимизировать вознаграждение** здесь и сейчас.

Пример:

Та же мышь, зная, где лежит маленький кусок сыра, возвращается туда каждый раз, не исследуя остальной лабиринт.

2. Почему этот компромисс так важен?

Если агент **только исследует** — он будет долго блуждать, не извлекая выгоды. Если он **только использует** — он может «застрять» на локальном максимуме, не найдя лучший путь.

Баланс исследование–использование

Идеальная стратегия должна **баланси́ровать**:

$$\text{Policy} = \text{balance}(\text{Exploration}, \text{Exploitation})$$

Мы хотим:

- **в начале** обучения — больше исследовать;
 - **по мере накопления опыта** — всё чаще использовать.
-

3. Иллюстрация: пример с мышью и сыром

На картинке из курса (Unit 1):

- Внизу — **много мелких сырков (+1)**;
- Наверху — **огромный запас сыра (+1000)**;
- По пути — **опасность (череп)**.

Если агент **всегда идёт к ближайшему вознаграждению** (эксплуатация) — он никогда не откроет, что сверху есть «супер-сыр». А если он **иногда пробует новые пути** (исследование) — рано или поздно он найдёт глобальный максимум.

4. Формальное представление

Компромисс можно записать как задачу максимизации **ожидаемого вознаграждения с учётом неопределённости**:

$$a_t = \arg \max_a [Q(s_t, a) + \beta \cdot U(s_t, a)]$$

где:

- $Q(s_t, a)$ — известная ценность действия (эксплуатация),
 - $U(s_t, a)$ — степень неопределённости или возможная выгода от изучения (исследование),
 - β — коэффициент, определяющий «жажду исследования».
-

5. Примеры стратегий управления балансом

5.1. ϵ -жадная стратегия (ϵ -greedy)

Простейший способ:

$$a_t = \begin{cases} \text{случайное действие,} & \text{с вероятностью } \epsilon \\ \arg \max_a Q(s_t, a), & \text{с вероятностью } 1 - \epsilon \end{cases}$$

- ϵ — вероятность исследовать.

- Обычно ε **уменьшается со временем**:

$$\varepsilon_t = \varepsilon_0 \cdot e^{-\lambda t}$$

где $\lambda > 0$ — скорость «остепенения» агента.

Пример:

- В начале: $\varepsilon = 0.3$ — агент часто пробует новые действия.
 - Позже: $\varepsilon = 0.05$ — агент в основном использует лучшее действие.
-

5.2. Softmax (Boltzmann Exploration)

Вместо случайного выбора действий — вероятности вычисляются через **температуру** τ :

$$P(a|s) = \frac{e^{Q(s,a)/\tau}}{\sum_b e^{Q(s,b)/\tau}}$$

- При **высокой** τ — действия выбираются почти случайно (исследование).
 - При **низкой** τ — агент выбирает почти всегда лучшее действие (эксплуатация).
-

5.3. Upper Confidence Bound (UCB)

Используется в контексте многоруких бандитов:

$$a_t = \arg \max_a \left(\bar{Q}(a) + c \sqrt{\frac{\ln t}{N(a)}} \right)$$

- $\bar{Q}(a)$ — среднее вознаграждение за действие a ,
- $N(a)$ — сколько раз оно пробовалось,
- c — параметр исследования.

Интуиция:

Чем реже действие пробовалось, тем больше стимул попробовать его снова.

6. Аналогия с реальной жизнью

Представь, что ты ищешь лучший ресторан в городе:

- **Exploitation**: ты идёшь каждый день в проверенное кафе — стабильно, но скучно.

- **Exploration:** ты пробуешь новое место — может быть ужасно, а может — это лучший ресторан в твоей жизни.

Хорошая стратегия — **сначала пробовать разные**, а потом **ходить в лучшие**.

7. Практическое значение

В алгоритмах RL (Q-learning, DQN, PPO и др.) этот баланс **встроен прямо в процесс обучения**:

- На ранних этапах агенты **много исследуют**;
- Со временем, благодаря улучшению аппроксимации $Q(s, a)$ или $\pi(a|s)$, они **фокусируются на лучших действиях**.

Краткий итог

Термин	Определение	Пример
Exploration	Изучение среды, проба случайных действий	Мышь идёт в неизвестный туннель
Exploitation	Использование накопленных знаний	Мышь возвращается к известному сыру
Компромисс	Баланс между этими двумя стратегиями	Иногда исследовать, иногда использовать
ϵ-greedy	Простая стратегия выбора	10% случайных действий
Softmax	Вероятностный выбор через температуру	Чем выше τ , тем больше случайности
UCB	Баланс на основе доверительного интервала	Пробовать то, что ещё мало исследовано

Основано на:

- Sutton & Barto, *Reinforcement Learning: An Introduction* (2020)

- Andrea Lonza, *Алгоритмы обучения с подкреплением на Python* (2020)
- RL Theory Book (Forts & Mills, 2022)