

Теоретический конспект №4

Тема: Два главных подхода к решению задач обучения с подкреплением

Связано с: [note 1.md](#) · [note 2.md](#) · [note 3.md](#)

1. Что мы хотим найти?

Мы уже знаем, что цель агента — найти **оптимальную стратегию** π^* , которая максимизирует ожидаемое вознаграждение:

$$\pi^* = \arg \max_{\pi} \mathbb{E}_{\pi}[G_t]$$

где

$$G_t = \sum_{k=0}^{\infty} \gamma^k r_{t+k+1}$$

2. Политика π : мозг агента

Политика (Policy) — это функция, определяющая поведение агента:

$$\pi(a|s) = P(A_t = a \mid S_t = s)$$

То есть политика говорит: «В состоянии s выбери действие a с такой-то вероятностью».

Цель обучения — найти такую политику π^* , при которой суммарное вознаграждение максимально.

3. Два подхода к поиску оптимальной политики

I. Policy-Based (Политико-ориентированные методы)

II. Value-Based (Ценностно-ориентированные методы)

4. Policy-Based Methods


Идея

Мы **учим саму функцию политики напрямую**, без оценки ценностей состояний. Она может быть:

- **детерминированной** — для каждого состояния выбирается одно действие;
- **стохастической** — для каждого состояния задаётся распределение вероятностей по действиям.

$$\pi_{\theta}(a|s)$$

где θ — параметры (например, веса нейросети).



Пример Policy-Based политики

Пример: стохастическая политика

Агент выбирает действие случайно, но **в зависимости от вероятностей**, предсказанных моделью:

$$\pi(a|s) = [0.1, 0.7, 0.2]$$

т.е. 70% — пойти направо, 10% — влево, 20% — прыгнуть.

Преимущества Policy-Based методов

- Хорошо работают в **непрерывных пространствах действий** (например, управление роботом).
 - Устойчивы — не страдают от резких скачков значений, как Q-функции.
 - Естественно описывают стохастические стратегии, что важно при **Exploration**.
-

Ограничения

- Требуют больше данных (variance высокая).
 - Градиенты по параметрам политики могут быть **нестабильными** → нужна аккуратная нормализация (например, REINFORCE, Actor-Critic, PPO).
-


Примеры алгоритмов

Алгоритм	Ключевая идея
REINFORCE	Чистый градиент политики $\nabla_{\theta} J(\theta)$
Actor-Critic	Комбинирует Policy-Based и Value-Based
PPO (Proximal Policy Optimization)	Устойчивое обновление политики с ограничением KL-дивергенции

5. Value-Based Methods

Основная идея

Вместо того чтобы напрямую учить политику, мы **оцениваем "ценность" состояний и действий**. То есть функция говорит: «*насколько хорошо находиться в этом состоянии или сделать это действие*».



Пример Value-Based подхода

Две функции ценности

1. Value-function (V-функция):

$$V_{\pi}(s) = \mathbb{E}_{\pi}[G_t | S_t = s]$$

— ожидаемое вознаграждение, начиная из состояния s .

2. Action-Value-function (Q-функция):

$$Q_{\pi}(s, a) = \mathbb{E}_{\pi}[G_t | S_t = s, A_t = a]$$

— ожидаемое вознаграждение, если сделать действие a в состоянии s , а потом следовать политике π .

Пример алгоритма на базе Q-функции — Q-Learning (off-policy TD control). Подробности и формула обновления см. в [note 9.md](#).

Оптимальная политика через Q-функцию

$$\pi^*(s) = \arg \max_a Q^*(s, a)$$

То есть агент выбирает действие с **наибольшей оценкой ценности**.

Преимущества Value-Based методов

- Простота — не нужно явно задавать стохастическую политику.

- Эффективны в дискретных задачах (Atari, FrozenLake, CartPole).
- Часто быстрее сходятся.

Недостатки

- Плохо работают в **непрерывных пространствах действий** — трудно искать максимум.
- Иногда страдают от **нестабильности обучения** (Q-функция может переоцениваться).
- Не моделируют вероятностное поведение (чисто детерминированные политики).
- **Проблема масштабирования:** в табличных методах (классический Q-Learning) требуется хранить значение для каждой пары (s, a) — невозможно для больших пространств состояний.

Решение проблемы масштабирования: Deep Q-Learning (DQN) использует нейронные сети для аппроксимации Q-функции. Подробнее в [note 5.md](#).

Основные алгоритмы

Алгоритм	Ключевая идея
Q-Learning	Обновляет $Q(s, a)$ по уравнению Беллмана
SARSA	"On-policy" версия Q-Learning
DQN (Deep Q-Network)	Аппроксимация $Q(s, a)$ нейросетью


6. Сравнение подходов

Характеристика	Value-Based	Policy-Based
Основная цель	Учим ценности состояний/действий	Учим политику напрямую
Тип действий	Дискретные	Непрерывные / стохастические
Сходимость	Быстрая, но нестабильная	Медленнее, но устойчивее
Примеры	Q-Learning, DQN	REINFORCE, PPO


Характеристика	Value-Based	Policy-Based
Применение	Игры, дискретные среды	Роботы, управление, сложные политики

Two approaches to find optimal policy π^* :

Policy-Based methods: train the agent to learn which action to take, given a state.



Value-Based methods: train the agent to learn which state is more valuable and take the action that leads to it.



Сравнение подходов Policy-Based и Value-Based подходов

7. Комбинированный подход: Actor–Critic

Современные методы объединяют обе идеи:

- **Actor** — это Policy-Based часть (выбирает действие);
- **Critic** — это Value-Based часть (оценивает, насколько это действие хорошее).

Итог:

Actor обновляет стратегию, Critic корректирует направление обучения с помощью оценки ценности.

$$\nabla_{\theta} J(\theta) \approx \nabla_{\theta} \log \pi_{\theta}(a_t | s_t) \cdot Q_{\pi}(s_t, a_t)$$

Резюме

Термин	Определение
Policy	Функция, задающая поведение агента
Value function	Оценка ожидаемого вознаграждения из состояния

Термин	Определение
Q-function	Оценка ожидаемого вознаграждения из пары (состояние, действие)
Value-Based	Учим ценности, выбираем $\max Q$
Policy-Based	Учим стратегию напрямую
Actor-Critic	Комбинируем оба подхода

Основано на:

- Sutton & Barto, *Reinforcement Learning: An Introduction* (2020)
- Andrea Lonza, *Алгоритмы обучения с подкреплением на Python* (2020)
- RL Theory Book (Forts & Mills, 2022)